Ik ben bezig met een zorgapplicatie die de folders van een ziekenhuis (HAGA) gebruikt om antwoord geven, dit is mijn huidige code. Ik had een vraag of het misschien een idee is om als een patient een vage vraag stelt, eerst een bericht te sturen van "bedoel je x , y of z" zodat daarna accurater antwoord gegeven kan worden, zou dit werkbaar zijn? Ik ben bang dat ik teveel op een talmodel ga leunen waardoor hallucinatie gehalte toe kan nemen:

PDF extraction

PyMuPDF>=1.24.0

Embeddings (lokaal)

sentence-transformers>=3.0.0
torch>=2.0.0

Vector store

chromadb>=0.5.0

LLM providers

openai>=1.30.0
httpx>=0.27.0

Backend

fastapi>=0.111.0
uvicorn>=0.30.0
python-dotenv>=1.0.0
python-multipart>=0.0.9

Text processing

tiktoken>=0.7.0

Scraper

requests>=2.31.0

=== LLM Provider ===

"ollama" voor lokaal (gratis), "openai" voor OpenAI API

LLM_PROVIDER=openai

=== Ollama (lokaal) ===

OLLAMA_BASE_URL=http://localhost:11434
OLLAMA_MODEL=llama3.1:8b

=== OpenAI ===

OPENAI_API_KEY=(geheime key)
OPENAI_MODEL=gpt-4o-mini

=== Embeddings ===

"local" voor sentence-transformers (GPU), "openai" voor OpenAI embeddings

EMBEDDING_PROVIDER=local

EMBEDDING_MODEL=intfloat/multilingual-e5-large

OPENAI_EMBEDDING_MODEL=text-embedding-3-small

=== Vector Store ===

CHROMA_PERSIST_DIR=./chroma_db

COLLECTION_NAME=haga_folders

=== RAG Settings ===

MIN_CHUNK_LENGTH=100

CHUNK_SIZE=300

CHUNK_OVERLAP=50

TOP_K=10

RELEVANCE_THRESHOLD=0.30

MAX_HISTORY_TURNS=6

=== HyDE (Hypothetical Document Embeddings) ===

Zet op "true" om HyDE retrieval te activeren.

HyDE kost één extra LLM-call per request maar verbetert retrieval

bij semantische mismatch tussen patiëntenvraag en foldertaal.

Gebruik eerst: python 2_test_retrieval.py --compare

om te meten of HyDE jouw corpus verbetert vóór je het aanzet.

HYDE_ENABLED=true

HYDE_MAX_TOKENS=200

HYDE_TEMPERATURE=0.3

HYBRID_ENABLED=true

BM25_INDEX_PATH=./bm25_index.pkl

RRF_K=60

BM25_WEIGHT=1.0

DENSE_WEIGHT=1.0

```text
```

```
## Hoe de RRF-weights te tunen

Na de eerste testrun kijk je in de terminal per query naar de debug-
output:
```

🔀 Hybrid RRF | dense=15 | bm25=15 | fused=10 | top3_rrf=[0.0312, 0.0290, 0.0278]

=== Server ===

HOST=0.0.0.0

PORT=8000

pasted-1.py pasted-2.py pasted-3.py pasted-4.py

Hé Sebastiaan. Goed om te zien dat jullie bij de denktank zo diep in de architectuur duiken. Je hebt echt een indrukwekkende, volwassen RAG-pipeline gebouwd voor het HagaZiekenhuis (Hybrid search, HyDE, BM25, dynamische prompts — heel netjes!).

Om direct antwoord te geven op je vraag: **Ja, een verduidelijkingsstap is een briljant idee, maar je angst voor hallucinaties is 100% terecht.**

Als je aan het LLM vraagt: *"De patiënt zegt 'mag ik douchen?', bedenk 3 mogelijke operaties"*, dan gaat het LLM inderdaad hallucineren en medische procedures verzinnen die het HagaZiekenhuis misschien niet eens uitvoert. Dat is een veiligheidsrisico.

Hier is hoe je dit als Computer Science student oplost: **Retrieval-Augmented Clarification**. Je laat niet het LLM de opties verzinnen, maar je gebruikt je Vector Database (Chroma) om de opties te dicteren.

Hoe bouw je dit veilig in je huidige code?

Het probleem van een vage vraag (bijv. *"Wat zijn de bijwerkingen?"*) is dat je in de vectorruimte resultaten krijgt uit compleet verschillende folders. Je kunt deze "spreiding" (entropie) in je resultaten gebruiken als een trigger.

Hier is de logica die je perfect in je `api/chat` endpoint kunt inbouwen:

1. De Trigger (Wanneer stel je een wedervraag?)

Je doet je normale `retrieve()` (Hybrid of HyDE). Kijk vervolgens naar de metadata van je Top-K chunks. Komen de top 4 resultaten uit 4 compleet verschillende folders? Dan is de vraag te vaag.

```python
# Pseudo-code voor in je /api/chat endpoint (na de retrieve stap)
chunks = retrieve(search_query, top_k=5)

# Verzamel unieke folder titels uit de resultaten
unieke_folders = list({chunk["metadata"]["title"] for chunk in chunks})

# Als de vraag kort is én we raken veel verschillende folders...
is_vage_vraag = len(req.message.split()) < 6
hoge_entropie = len(unieke_folders) >= 3

if is_vage_vraag and hoge_entropie:
    # LLM NIET laten nadenken! Gebruik keihard de metadata.
    opties = "\n".join([f"- {titel}" for titel in unieke_folders[:3]])

    wedervraag = (
        "Uw vraag kan over meerdere behandelingen gaan. "
        "Kunt u aangeven welke folder u bedoelt? Bedoelt u
bijvoorbeeld:\n"
        f"{opties}\n"
        "- Of gaat het over iets anders?"
    )
    return ChatResponse(answer=wedervraag, sources=[])
```

2. Waarom dit jouw architectuur verbetert

- **Zero Hallucinatie:** De opties (X, Y, Z) komen letterlijk uit `chunk["metadata"]["title"]`. Je toont alleen folders die écht in jullie database zitten.
- **Beschermt je HyDE:** Je gebruikt momenteel HyDE (`HYDE_ENABLED=true`). HyDE is fantastisch, maar *levensgevaarlijk* bij vage vragen. Als ik vraag *"Mag ik autorijden?"*, gaat HyDE een hypothetisch antwoord genereren. Misschien verzint HyDE een antwoord over oogchirurgie, waardoor je retriever ineens blind staart op oog-folders, terwijl de patiënt een knie-operatie had. Bovenstaande filter voorkomt dat HyDE ontspoort.
- **UX voor de patiënt:** Het voelt heel natuurlijk en slim aan. De AI zegt in feite: *"Ik zie in onze bibliotheek regels voor autorijden bij Cardiologie, Oogheelkunde en Orthopedie. Welke zoekt*

u?"

Implementatietip voor je Frontend

Je kunt dit nog mooier maken door de `unieke_folders` als klikbare *suggested replies* (chips/buttons) mee te sturen naar je frontend in je `ChatResponse` model, in plaats van alleen in de tekst.

Je voorgevoel als AI-student is dus spot-on: leun niet op de *generatieve* kant van het model voor de opties, maar leun op de *retrieval* kant. Data-gedreven wedervragen stellen is de heilige graal voor betrouwbare medische chatbots.

Succes met de denktank, klinkt als een gaaf project om het HagaZiekenhuis verder te helpen! Heb je vragen over hoe je dit in je HyDE flow integreert?

DIt is de front-end btw, in welke file moet ik het eerder gegeven code stuk overnemen? Is dat voor server.py?

Stopped by user

DIt is de front-end btw, in welke file moet ik het eerder gegeven code stuk overnemen? Is dat voor server.py?

pasted-1.html

Ja, helemaal correct! Dit stukje logica hoort **uitsluitend in de backend** thuis, dus in jouw `server.py`. Je frontend hoef je hiervoor niet aan te passen, want die print gewoon netjes het antwoord (`data.answer`) op het scherm, of dat nou een definitief antwoord is of een wedervraag.

Door dit in `server.py` af te vangen, voorkom je niet alleen hallucinaties, maar **bespaar je ook dure API-calls of zware lokale GPU-rekenkracht**, omdat je de generatie-stap van het LLM volledig overslaat.

Waar precies in `server.py` ?

Je plaatst dit in de `async def chat(req: ChatRequest):` functie, **direct ná de retrieval stap** en **vóórdat je de system prompt bouwt en het LLM aanroept**.

Zoek in je `server.py` naar dit stukje (rond regel 415) en voeg het `2b. Anti-Hallucinatie` blok toe:

```python
    # ── 2. Retrieve + sibling chunks ──
    chunks = retrieve(search_query, top_k=req.top_k)
    # Voeg aangrenzende chunks toe van gevonden folders.
    chunks = fetch_sibling_chunks(chunks, window=2)

    # ============================================================================
    # NIEUW: 2b. Retrieval-Augmented Clarification (Anti-Hallucinatie)
    # ============================================================================
    if chunks and not req.history:
        # Haal unieke titels op met behoud van volgorde (relevantie)
        unieke_folders = []
        for c in chunks:
            # Pak de titel, of val terug op filename als titel mist
            titel = c["metadata"].get("title", c["metadata"].get("filename", "Onbekend"))
            # Maak het mooi op (haal bijv. '.pdf' weg mocht dat erin staan)
            titel = titel.replace(".pdf", "").strip()

            if titel not in unieke_folders:
                unieke_folders.append(titel)

        # Detectie heuristiek: Is de vraag kort? En schieten we met hagel (3+ mappen)?
        is_vage_vraag = len(req.message.split()) <= 6
        hoge_entropie = len(unieke_folders) >= 3

        if is_vage_vraag and hoge_entropie:
            print(f"🔴 VAGE VRAAG FILTER | Vraag: '{req.message}' | Mappen: {len(unieke_folders)}")

            # Bouw de wedervraag met de Top 3 gevonden folders
            opties_tekst = "\n".join([f"• {titel}" for titel in unieke_folders[:3]])
```

```
            wedervraag = (
                "Uw vraag is wat algemeen en kan over meerdere
behandelingen gaan. "
                "Om u het beste te helpen, over welk onderwerp gaat uw
vraag?\n\n"
                f"{opties_tekst}\n\n"
                "Of zoekt u informatie over iets anders?"
            )

            # Stuur direct terug! We roepen de LLM
(generate_openai/ollama) NIET aan.
            # Geef lege sources array mee zodat de frontend geen vage
bron-chips toont.
            return ChatResponse(answer=wedervraag, sources=[])
    #
==========================================================================

    context = build_context(chunks)

    # 3. Veiligheidscheck: geen relevante chunks gevonden
    if not chunks:
```

Waarom deze code zo precies en veilig werkt:

1. **`if chunks and not req.history:`**
   Ik heb bewust **`not req.history`** toegevoegd. Waarom? Omdat vervolgvragen vaak kort zijn (bijv: *"En mag ik daarna douchen?"* of *"Doet dat pijn?"*). Als de patiënt al in een diep gesprek zit, is de vraag wel kort, maar *niet* vaag (want de eerdere geschiedenis biedt de context). Je wilt dit filter vooral op de **allereerste vraag** van een chatsessie toepassen.
2. **Kosten-efficiënt:** De **`retrieve`** is een simpele lokale similarity search met je embedding model (super snel). Als de code besluit dat het vaag is, stopt de functie via de **`return`**. Je raakt de zware LLM (**`generate`**) niet eens aan.
3. **Frontend ready:** Je front-end pakt die **`\n\n• Titel`** perfect op. Het zal eruitzien als een hele professionele, gestructureerde wedervraag en via TTS mooi worden voorgelezen als de gebruiker op "Lees voor" klikt.

Zodra de patiënt dan antwoordt met: *"Ik bedoel de eerste"* of *"Over de staaroperatie"*, pakt de volgende loop de geschiedenis wel mee, valt niet meer in de filter-val, en de **`rewrite_query_with_context`** functie die jij al in je code had staan lost de rest prachtig op!

De error:

```
ERROR: Exception in ASGI application
Traceback (most recent call last):
File "C:\RAG2.venv\Lib\site-packages\uvicorn\protocols\http\httptools_impl.py", line 416, in run_asgi
result = await app( # type: ignore[func-returns-value]
^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
self.scope, self.receive, self.send
^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
)
^
File "C:\RAG2.venv\Lib\site-packages\uvicorn\middleware\proxy_headers.py", line 60, in __call__
return await self.app(scope, receive, send)
^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
File "C:\RAG2.venv\Lib\site-packages\fastapi\applications.py", line 1159, in __call__
await super().__call__(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\starlette\applications.py", line 90, in __call__
await self.middleware_stack(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\starlette\middleware\errors.py", line 186, in __call__
raise exc
File "C:\RAG2.venv\Lib\site-packages\starlette\middleware\errors.py", line 164, in __call__
await self.app(scope, receive, _send)
File "C:\RAG2.venv\Lib\site-packages\starlette\middleware\exceptions.py", line 63, in __call__
await wrap_app_handling_exceptions(self.app, conn)(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\starlette_exception_handler.py", line 53, in wrapped_app
raise exc
File "C:\RAG2.venv\Lib\site-packages\starlette_exception_handler.py", line 42, in wrapped_app
await app(scope, receive, sender)
File "C:\RAG2.venv\Lib\site-packages\fastapi\middleware\asyncexitstack.py", line 18, in __call__
await self.app(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\starlette\routing.py", line 660, in __call__
await self.middleware_stack(scope, receive, send)
```

```
File "C:\RAG2.venv\Lib\site-packages\starlette\routing.py", line 680, in app
await route.handle(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\starlette\routing.py", line 276, in handle
await self.app(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\fastapi\routing.py", line 134, in app
await wrap_app_handling_exceptions(app, request)(scope, receive, send)
File "C:\RAG2.venv\Lib\site-packages\starlette_exception_handler.py", line 53, in
wrapped_app
raise exc
File "C:\RAG2.venv\Lib\site-packages\starlette_exception_handler.py", line 42, in
wrapped_app
await app(scope, receive, sender)
File "C:\RAG2.venv\Lib\site-packages\fastapi\routing.py", line 120, in app
response = await f(request)
^^^^^^^^^^^^^^^^
File "C:\RAG2.venv\Lib\site-packages\fastapi\routing.py", line 674, in app
raw_response = await run_endpoint_function(
^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
...<3 lines>...
)
^
File "C:\RAG2.venv\Lib\site-packages\fastapi\routing.py", line 328, in run_endpoint_function
return await dependant.call(**values)
^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
File "C:\RAG2\server.py", line 711, in chat
chunks = fetch_sibling_chunks(chunks, window=2)
File "C:\RAG2\server.py", line 410, in fetch_sibling_chunks
chunks = retrieve(search_query, top_k=req.top_k)
^^^^^^^^^^^^
NameError: name 'search_query' is not defined
```

De code:

pasted-2.py

Ah, ik zie precies wat er mis is gegaan! Het is een klassiek copy-paste foutje.

Je hebt de nieuwe code per ongeluk **ín de functie** `fetch_sibling_chunks` geplakt (rond regel 408), in plaats van in de `async def chat(req: ChatRequest):` endpoint (helemaal onderaan rond regel 710).

Omdat je het in de `fetch_sibling_chunks` functie hebt geplakt, kent Python de variabelen `search_query` en `req` daar helemaal niet (vandaar de `NameError`). Bovendien zou het zorgen voor een oneindige loop (de functie roept daar zichzelf weer aan).

Geen zorgen, we gaan dit in twee simpele stappen herstellen!

Stap 1: Herstel de `fetch_sibling_chunks` functie

Zoek in jouw `server.py` naar `def fetch_sibling_chunks` (rond regel 392). **Verwijder de foute code die je daar hebt geplakt** en zorg dat de functie er weer exact zo uitziet:

```python
def fetch_sibling_chunks(chunks: list[dict], window: int = 2) ->
list[dict]:
    """
    Haal aangrenzende chunks op voor elk gevonden document.

    Het probleem: bij een folder over de daglounge scoort chunk 0
    (de intro) hoog, maar de openingstijden staan in chunk 1 of 2.
    Die lagere chunks vallen buiten TOP_K en worden nooit aan het
    LLM gegeven.

    Oplossing: voor elk uniek document in de resultaten, haal ook
    chunk_index ± window op uit ChromaDB. Voeg die toe aan de context
    met een lagere similarity-score zodat het LLM ze als aanvullend
    beschouwt.
    """
    # VEILIGHEIDSCHECK: Dit is de originele, correcte start van deze
functie!
    if not chunks:
        return chunks

    # Verzamel welke (filename, chunk_index) combinaties we al hebben
    seen_ids: set[str] = set()
    for c in chunks:
```

```
        meta = c["metadata"]
        fname = meta.get("filename", "")
        cidx = meta.get("chunk_index", -1)
        seen_ids.add(f"{fname}::{cidx}")

    extra_chunks = []

    # Per gevonden chunk: haal siblings op via metadata-filter
    for chunk in chunks:
        meta = chunk["metadata"]
        fname = meta.get("filename", "")
        cidx = int(meta.get("chunk_index", -1))
        total = int(meta.get("total_chunks", 0))

        if not fname or cidx < 0:
            continue

        for offset in range(-window, window + 1):
            if offset == 0:
                continue  # al aanwezig
            target_idx = cidx + offset
            if target_idx < 0 or (total > 0 and target_idx >= total):
                continue
            uid = f"{fname}::{target_idx}"
            if uid in seen_ids:
                continue

            # ChromaDB metadata-query op filename + chunk_index
            try:
                r = collection.get(
                    where={"$and": [
                        {"filename": {"$eq": fname}},
                        {"chunk_index": {"$eq": target_idx}},
                    ]},
                    include=["documents", "metadatas"],
                )
                if r["documents"]:
                    seen_ids.add(uid)
                    sibling_sim = max(chunk["similarity"] - 0.05, 0.0)
                    extra_chunks.append({
                        "text": r["documents"][0],
                        "metadata": r["metadatas"][0],
                        "distance": round(1 - sibling_sim, 3),
                        "similarity": round(sibling_sim, 3),
                        "_is_sibling": True,
                    })
            except Exception:
                pass
```

```
    if extra_chunks:
        print(f"   +{len(extra_chunks)} sibling chunks toegevoegd")

    all_chunks = chunks + extra_chunks

    seen_final: set[str] = set()
    deduped = []
    for c in all_chunks:
        uid =
f"{c['metadata'].get('filename','')}::{c['metadata'].get('chunk_index','')
}"
        if uid not in seen_final:
            seen_final.add(uid)
            deduped.append(c)

    return deduped
```

Stap 2: Zet de nieuwe logica op de juiste plek in de `chat` functie

Scroll nu helemaal naar beneden naar de API endpoints, bij **`async def chat(req: ChatRequest):`** (rond regel 670). Scroll iets verder naar beneden ín die functie totdat je **`# — 2. Retrieve + sibling chunks —`** ziet.

Daar plak je ons nieuwe Anti-Hallucinatie blok, zodat het er zo uitziet:

```python
    # — 2. Retrieve + sibling chunks —
    chunks = retrieve(search_query, top_k=req.top_k)
    # Voeg aangrenzende chunks toe van gevonden folders.
    # Hierdoor mist de LLM geen openingstijden/instructies die net buiten
    # de top-K vielen maar wél in dezelfde folder staan als een gevonden
chunk.
    chunks = fetch_sibling_chunks(chunks, window=2)

    #
==========================================================================
    # NIEUW: 2b. Retrieval-Augmented Clarification (Anti-Hallucinatie)
    #
==========================================================================
    if chunks and not req.history:
        # Haal unieke titels op met behoud van volgorde (relevantie)
        unieke_folders = []
        for c in chunks:
            # Pak de titel, of val terug op filename als titel mist
```

```
            titel = c["metadata"].get("title",
c["metadata"].get("filename", "Onbekend"))
            # Maak het mooi op (haal bijv. '.pdf' weg mocht dat erin
staan)
            titel = titel.replace(".pdf", "").strip()

            if titel not in unieke_folders:
                unieke_folders.append(titel)

        # Detectie heuristiek: Is de vraag kort? En schieten we met hagel
(3+ mappen)?
        is_vage_vraag = len(req.message.split()) <= 6
        hoge_entropie = len(unieke_folders) >= 3

        if is_vage_vraag and hoge_entropie:
            print(f"🔴 VAGE VRAAG FILTER | Vraag: '{req.message}' |
Mappen: {len(unieke_folders)}")

            # Bouw de wedervraag met de Top 3 gevonden folders
            opties_tekst = "\n".join([f"• {titel}" for titel in
unieke_folders[:3]])
            wedervraag = (
                "Uw vraag is wat algemeen en kan over meerdere
behandelingen gaan. "
                "Om u het beste te helpen, over welk onderwerp gaat uw
vraag?\n\n"
                f"{opties_tekst}\n\n"
                "Of zoekt u informatie over iets anders?"
            )

            # Stuur direct terug! We roepen de LLM
(generate_openai/ollama) NIET aan.
            # Geef lege sources array mee zodat de frontend geen vage
bron-chips toont.
            return ChatResponse(answer=wedervraag, sources=[])
    #
==========================================================================

    context = build_context(chunks)

    # 3. Veiligheidscheck: geen relevante chunks gevonden
    if not chunks:
```

Sla dit op, restart je Uvicorn/FastAPI server en probeer via de browser een korte, algemene term in te typen (bijv. "operatie" of "douchen"). Je zult zien dat hij het nu perfect afvangt en niet meer crasht!

Hij doet wat ie hoort, maar dit is natuurlijk niet echt nuttig:

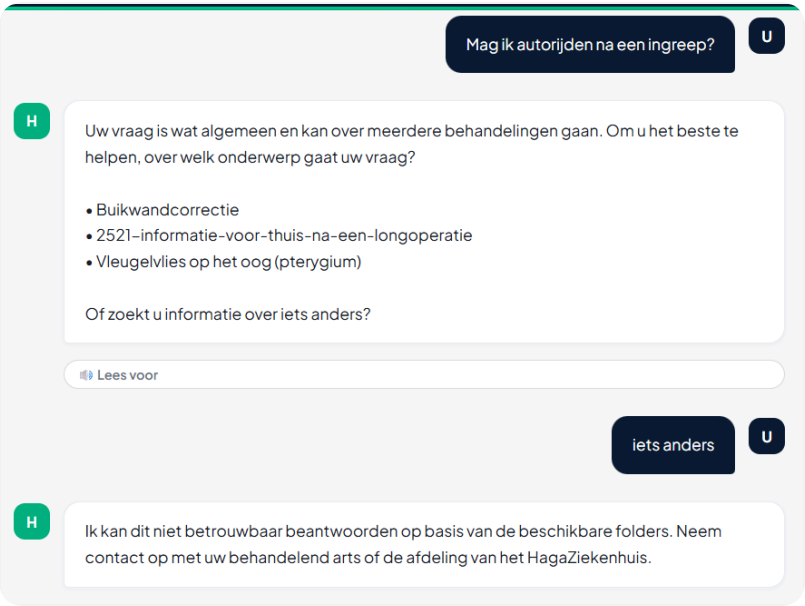

Haha, oeps! Je hebt helemaal gelijk. Dit is het klassieke probleem met multi-turn RAG-systemen: ze missen het "gezonde verstand" om een gesprek goed op te slaan.

Wat hier misging onder de motorkap:
Toen jij *"iets anders"* typte, stuurde de code letterlijk de zoekopdracht *"iets anders"* naar je vector database. Jouw ChromaDB is wanhopig op zoek gegaan naar patiëntenfolders over de aandoening "Iets Anders". Dat leverde ruis op, de LLM zag de ruis, wist (terecht) van niks, en gooide de handdoek in de ring.

Hetzelfde probleem zou optreden als je wel had gekozen: *"Buikwandcorrectie"*. De RAG had dan alleen naar "buikwandcorrectie" gezocht, en was vergeten dat de oorspronkelijke vraag over "autorijden" ging!

De Oplossing: Een "Geheugenbrug" bouwen

We moeten in je backend afvangen of de gebruiker momenteel antwoord geeft op ons eigen keuzemenu.

1. Als de gebruiker *"iets anders"* zegt -> dan vangen we dat af en vragen we direct om verduidelijking (zonder ChromaDB of LLM aan te roepen).
2. Als de gebruiker *"Buikwandcorrectie"* zegt -> dan herschrijven we de vraag onzichtbaar naar: *"Mag ik autorijden na een ingreep? (Focus op: Buikwandcorrectie)"*. Dán werkt de vector

search fantastisch!

Waar plak je dit in `server.py` ?

Zoek in je `server.py` de `async def chat(req: ChatRequest):` op (rond regel 670). Plaats dit blok **direct onder het 0. Crisis-check** blok, en vlak vóór **1. Query expansion**.

```python
    # ── 0. Crisis-check — altijd als eerste, vóór RAG ──
    msg_lower = req.message.lower()
    if any(signal in msg_lower for signal in CRISIS_SIGNALS):
        print(f"🚨 CRISIS GEDETECTEERD: '{req.message[:60]}'")
        return ChatResponse(answer=CRISIS_RESPONSE, sources=[])

    # ============================================================================
    # NIEUW: 0b. Clarification Flow Intercept
    # Vang het antwoord van de gebruiker af als we zojuist het keuzemenu toonden
    # ============================================================================
    if req.history and len(req.history) >= 2:
        # Check of het laatste bericht van de bot ons keuzemenu was
        last_bot_msg = req.history[-1].get("content", "")
        if "Uw vraag is wat algemeen en kan over meerdere behandelingen gaan" in last_bot_msg:
            msg_lower = req.message.lower().strip()

            # Scenario A: Gebruiker zegt "iets anders", "geen van beide", "nee"
            if any(word in msg_lower for word in ["anders", "geen", "nee", "overige", "niets"]):
                return ChatResponse(
                    answer="Kunt u in een paar woorden aangeven over welke specifieke ingreep, aandoening of afdeling u een vraag heeft?",
                    sources=[]
                )

            # Scenario B: Gebruiker kiest een optie (bijv. "Buikwandcorrectie")
            # We combineren zijn originele vraag (uit de history) met zijn antwoord!
            originele_vraag = req.history[-2].get("content", "")

            # Herschrijf het req.message onzichtbaar voor de hele verdere
```

```
RAG pipeline
            req.message = f"{originele_vraag} (Focus op: {req.message})"
            print(f"🔄 Vraag herschreven na keuzemenu: '{req.message}'")
    #
==========================================================================

    # ── 1. Query expansion — gebruik ASSISTANT-context, niet user-context
──
```

Waarom is deze techniek zo elegant voor jouw Denktank?

Je verandert hiermee de *staat* van het gesprek voordat de rest van het algoritme het überhaupt door heeft. Doordat je `req.message` overschrijft, gaat jouw inkomende `"Buikwandcorrectie"` vanaf nu door de hele pijplijn als: *"Mag ik autorijden na een ingreep? (Focus op: Buikwandcorrectie)"*.

1. Je *Embedder* snapt nu exact welke folderafdeling hij moet hebben én zoekt naar autorijden.
2. Je *LLM* krijgt deze samengevoegde zin binnen en snapt in één klap de hele context van het gesprek.

Test het maar eens uit: kies hierna eens een optie of typ "iets anders", je RAG zal zich ineens super slim gedragen!

> Zou het nuttig zijn om informatie "gaps" op te kunnen vullen door een hierarische model te maken (met informatie van thuisarts.nl bijvoorbeeld). om betrouwbare informatie voor algemenere probleem, wel dat als informatie in beide staat, HAGA prioriteit heeft.

Wat een fantastisch idee, Sebastiaan. Je raakt hiermee precies de kern van de huidige "next-level" enterprise RAG-systemen: **Multi-Source Routing** of **Fallback RAG**.

Voor een denktank is dit een ontzettend sterk punt om in te brengen. Hier is mijn kritische blik op *waarom* dit geniaal is, de *gevaren* in de zorg, en hoe je dit als AI-student technisch elegant oplost.

1. Waarom dit enorm nuttig is (De Informatiekloof)

Patiënten snappen het verschil niet tussen ziekenhuisinformatie en algemene medische informatie.

- **HAGA Folders** zijn gericht op *procedures en nazorg* ("Hoe bereid ik me voor op de staaroperatie?").
- **Patiënten** stellen vaak vragen over *diagnoses of algemene klachten* ("Wat is staar eigenlijk precies?" of "Mijn oog is rood, wat nu?").
  Als jouw bot nu alleen HAGA-folders heeft, loopt hij snel vast op dat soort algemene vragen. Thuisarts.nl (beheerd door het NHG) is de absolute gouden standaard in Nederland om dat gat te dichten.

2. De Medicus-Criticus: Waar zit het gevaar?

Protocollen botsen. Thuisarts.nl geeft algemeen advies (bijv. *"Neem bij pijn gerust een paracetamol"* of *"U mag weer eten als u zich goed voelt"*). Maar het HagaZiekenhuis heeft voor een *specifieke* operatie misschien een afwijkend, strak protocol (*"Absoluut nuchter blijven tot de arts is langsgeweest"*).

Als jouw AI de HAGA-informatie én de Thuisarts-informatie tegelijk in de `context` gooit, gaat het LLM ze blenden. Dat is levensgevaarlijk in een medische applicatie. De hiërarchie moet **keihard** zijn.

3. Hoe bouw je een strikt Hiërarchisch Model (Technisch)

Je moet de bronnen scheiden. Je doet dit door twee aparte ChromaDB collections te maken (of een metadata-filter toe te passen) en een **Sequential Router** te schrijven.

Je past je code in `server.py` conceptueel zo aan:

```python
def retrieve_hierarchical(query: str, top_k: int = 5):
    # STAP 1: Zoek ALTIJD eerst in de HAGA folders
    haga_chunks = retrieve_from_collection("haga_folders", query, top_k)

    # Check of HAGA een écht goed antwoord heeft (strenge threshold)
```

```
    if haga_chunks and haga_chunks[0]["similarity"] >= 0.50:
        return haga_chunks, "HAGA"

    # STAP 2: Geen goed HAGA antwoord? Fallback naar Thuisarts.nl
    thuisarts_chunks = retrieve_from_collection("thuisarts_db", query,
top_k)

    # Check of Thuisarts het wel weet
    if thuisarts_chunks and thuisarts_chunks[0]["similarity"] >= 0.40:
        return thuisarts_chunks, "THUISARTS"

    # STAP 3: Niemand weet het -> Verwijs naar de arts
    return [], "NONE"
```

4. Transparantie in je Prompting (Cruciaal!)

Als je AI terugvalt op Thuisarts.nl, moet de patiënt (en het LLM) dat weten om verwachtingen te managen. In je system prompt voeg je dan dynamisch dit toe:

- **Als de bron HAGA is:** *"Beantwoord de vraag op basis van de HagaZiekenhuis protocollen."*
- **Als de bron Thuisarts is:** *"Je kon de informatie niet vinden in de HAGA folders. Je beantwoordt de vraag nu op basis van algemene Thuisarts.nl richtlijnen. VERPLICHTE INSTRUCTIE: Begin je antwoord met de zin: 'Hier is geen specifieke folder van het HagaZiekenhuis over, maar volgens algemene medische richtlijnen (Thuisarts.nl) geldt het volgende...'"*

Conclusie voor je denktank

Dit is absoluut werkbaar en toont aan dat jullie verder denken dan een simpele 'chat-with-pdf' kloon. Je bouwt een gelaagd informatiesysteem.

Mijn advies voor jullie pitch:
Stel voor om te beginnen met een "Single-Source of Truth" (alleen HAGA). Maar pitch dit Fallback-model (met Thuisarts.nl) als dé visie voor "Fase 2", waarbij je expliciet benadrukt hoe je via *Sequential Retrieval* de medische veiligheid (HAGA protocollen gaan vóór alles) garandeert. Dat soort architectuur-denken vinden artsen en ziekenhuisbesturen prachtig.

Zou je dit willen inbouwen, of hou je het voor nu bij de theorie voor de pitch?